

Table des matières

Cours 12 — SQL analytique appliqué.....	1
Objectifs.....	1
Théorie.....	2
Points clés à retenir.....	5
Exercices.....	6

Cours 12 — SQL analytique appliqué

Module 12/12 — Formation SQL avancé

Comment lire ce module — Ce n'est pas un cours de plus, c'est un projet. La théorie est courte et ne présente aucune notion nouvelle : elle cadre le cas, elle donne la méthode, et elle dit ce qu'on attend de vous. Tout le travail est dans `Labo_12_OLAP.md`, qui se mène d'un bout à l'autre en une séance ou deux. Un seul laboratoire, sur l'entrepôt, parce qu'un tableau de bord de ventes est une question analytique et que c'est là qu'on la traite. Les exercices ne demandent presque pas de SQL : ils demandent de défendre vos choix, ce qui est exactement ce qu'un entretien technique évalue.

Objectifs

À la fin de ce module, vous saurez :

- cadrer une demande floue en une question précise, avec un grain et une définition de chaque mesure ;
- décider ce qu'un chiffre absent doit valoir, et l'écrire quelque part ;
- contrôler la qualité d'un jeu de données avant de le mesurer, et non après ;
- assembler en un seul livrable ce que les modules précédents ont enseigné séparément ;
- mesurer ce que votre rapport coûte, et l'améliorer sur des faits ;
- rendre votre chargement rejouable, donc exploitable par quelqu'un d'autre que vous ;
- défendre chacun de vos choix devant quelqu'un qui aurait choisi autrement.

Théorie

1. Ce que le capstone demande

Labo : Labo_12_OLAP.md, partie 1.

Les onze modules précédents vous ont donné des outils, un par un, dans des conditions choisies pour les mettre en valeur. Un projet réel ne se présente jamais comme ça. Il arrive sous la forme d'une phrase vague, sur une donnée dont personne ne connaît les défauts, avec une échéance et un lecteur qui n'a pas envie d'entendre parler de fenêtres glissantes.

Ce module reconstitue ces conditions. La demande de départ tient en une phrase, et elle est volontairement insuffisante :

Il nous faudrait un tableau de bord des ventes en ligne, avec la tendance et les meilleurs produits.

Trois mots de cette phrase sont indéfinis, et votre première tâche est de vous en apercevoir. Ce n'est pas un exercice de rhétorique : chacun des trois se traduit par une décision technique différente, et le rapport n'est pas le même selon la décision.

2. La méthode, en cinq temps

Labo : Labo_12_OLAP.md, partie 1.

L'ordre compte plus que les outils, et c'est la principale chose que ce module veut transmettre.

Cadrer. On transforme la demande en question précise. Quel est le grain, c'est-à-dire ce qu'une ligne du résultat représente. Quelle est la période, et jusqu'où elle est complète. Comment se définit chaque mesure, en une phrase qu'un non-technicien peut valider. Ce travail se fait avant d'écrire du SQL, et il ne se rattrape pas après.

Contrôler. On vérifie la donnée avant de la mesurer. Des lignes de fait sans dimension, des clés en double, des dates incohérentes, des périodes tronquées aux bords. Ces contrôles sont du SQL ordinaire, ils prennent dix minutes, et ils décident si le reste vaut quelque chose.

Construire. On assemble le rapport, en couches lisibles plutôt qu'en une requête géante. Chaque couche a un nom et une responsabilité, et on peut la lire seule.

Mesurer. On regarde ce que le rapport coûte, et on améliore ce qui mérite de l'être. Pas avant : optimiser un rapport dont on n'a pas encore vérifié l'exactitude est du travail perdu deux fois.

Rendre rejouable. On fait en sorte que le chargement puisse être relancé sans dommage, et qu'un lecteur ne voie jamais un état intermédiaire. C'est l'étape que tout le monde saute, et c'est celle qui décide si votre travail survit à votre départ.

3. Le cas, et le grain

Labo : Labo_12_OLAP.md, sous-parties 1.1 et 1.2.

Le cas porte sur `dbo.FactInternetSales`, les ventes en ligne d'Adventure Works, avec ses dimensions de produit, de date, de client et de territoire.

La question du grain se pose immédiatement, parce que le fait ne porte pas le grain qu'on croit. Une ligne de `dbo.FactInternetSales` est un article d'une commande, pas une commande. Compter les lignes donne donc un nombre d'articles vendus, et non un nombre de commandes : 60 398 d'un côté, 27 659 de l'autre, soit plus du double. Une bonne part des tableaux de bord faux le sont pour cette seule raison.

Le rapport visé aura donc plusieurs grains, et il faut les nommer avant de commencer.

Grain	Une ligne représente	Ce qu'on y mesure
Article	un produit dans une commande	quantité, montant, marge
Commande	une commande complète	panier moyen, nombre de commandes
Jour	une journée	ventes, tendance, moyenne mobile
Produit et mois	un produit dans un mois	classement, part du total

Passer d'un grain à l'autre n'est jamais gratuit. Compter des commandes dans une requête au grain article demande un `COUNT(DISTINCT ...)`, et sommer un montant de commande au grain article le compte autant de fois qu'il y a d'articles. C'est la faute la plus fréquente de tout le module.

4. Les huit étapes, et ce que chacune remobilise

Labo : `Labo_12_OLAP.md`, parties 2, 3, 4, 5, 6, 7 et 8.

Le laboratoire suit huit étapes, et chacune rappelle un module. Ce tableau est la carte du travail.

Étape	Ce qu'on fait	Module remobilisé
1	Cadrer la question, fixer le grain, lire le modèle	Cours 01
2	Reconstituer la série sans trous	Cours 05
3	Poser les mesures : cumuls, parts, classements	Cours 04
4	Contrôler la qualité par anti-jointures	Cours 07
5	Rattacher le prix en vigueur par as-of join	Cours 09
6	Produire le rapport avec sous-totaux, au format long	Cours 06
7	Mesurer ce que ça coûte et optimiser	Cours 10
8	Rendre le chargement rejouable	Cours 11

L'étape 8 est celle qui fait du capstone autre chose qu'un exercice. Elle oblige à revenir sur la partie B, que le lecteur pressé aurait pu sauter, et à constater qu'elle lui manquait. Un rapport juste qu'on ne peut pas relancer sans le casser n'est pas un livrable.

Une précision s'impose sur les étapes 7 et 8, parce que la partie B s'est enseignée sur le transactionnel et que le capstone se fait sur l'entrepôt. Tout n'y revient pas, et il vaut mieux savoir quoi.

De la partie B	Revient ici	Ne revient pas
Cours 10	la sargabilité, qui coûte des deux côtés, et la lecture d'un profil d'exécution	les index B-tree, composites et couvrants, qui n'ont pas d'objet sur l'entrepôt
Cours 11	l'atomicité d'un chargement et son idempotence, qui valent partout	les niveaux d'isolation, les verrous et le MVCC, faute de plusieurs écrivains

Ce qui revient n'est donc pas la mécanique des deux modules, c'est ce qu'ils ont de transposable : ne pas toucher à la colonne qu'on filtre, mesurer plutôt que deviner, et faire en sorte qu'un chargement puisse échouer au milieu sans laisser un état bâtarde. C'est peu de mots et c'est beaucoup de travail, comme vous le verrez aux parties 7 et 8 du laboratoire.

Un module manque à ce tableau, le Cours 08, et son absence est délibérée. L'entrepôt d'Adventure Works ne contient aucune donnée semi-structurée, et fabriquer du JSON pour l'occasion irait contre la leçon de ce module, qui est de ne pas en mettre là où il n'y a pas lieu. Si votre source réelle en contenait, l'étape correspondante viendrait juste avant l'étape 4 : on aplatit, on type, puis on contrôle.

5. Ce qu'on attend de vous

Labo : Labo_12_OLAP.md, parties 6 et 9.

Le livrable n'est pas une requête, c'est un ensemble.

Livrable	Ce qu'il contient
La note de cadrage	le grain, la période, la définition de chaque mesure, et les décisions prises sur les cas limites
Le rapport de contrôle	les requêtes de qualité et leur résultat, y compris quand elles ne trouvent rien
Les vues du rapport	une par couche, nommées, lisibles séparément
La note de performance	ce que le rapport coûte, ce que vous avez changé, et ce que ça a donné
Le chargement	le bloc rejouable, et le moyen de savoir qu'il est allé au bout

La note de cadrage est celle qu'on oublie, et c'est celle qui a le plus de valeur six mois plus tard. Un chiffre sans définition n'est pas un chiffre, c'est une source de discussions.

Deux critères jugent le tout, et ce sont ceux d'un entretien technique. Le résultat est-il juste, ce qui se démontre par les contrôles plutôt que par la confiance. Et sauriez-vous défendre chaque choix devant quelqu'un qui aurait choisi autrement, ce qui suppose que vous ayez su qu'il y avait un choix.

6. Ce que ce module ne fait pas

Labo : Labo_12_OLAP.md, partie 9.

Trois choses sortent volontairement du cadre, et il vaut mieux savoir où elles vivent.

L'orchestration, c'est-à-dire ce qui déclenche le chargement, gère ses dépendances et alerte quand il échoue. C'est le sujet de la formation Analytics Engineering, avec dbt.

La restitution, c'est-à-dire l'outil qui affiche le tableau de bord, ses filtres et son modèle sémantique. Elle appartient aussi à la formation Analytics Engineering, du côté de Power BI.

L'administration de la plateforme, les rôles, les entrepôts de calcul, la gouvernance des accès. C'est le sujet de la formation Snowflake.

Ce module reste sur le langage, ce qui est la frontière de toute la formation. Ce que vous produisez ici est la couche SQL sur laquelle les deux autres formations viennent se poser.

Points clés à retenir

- Un projet réel arrive sous forme de phrase vague. Repérer ce qui n'est pas défini est la première tâche, pas une politesse.
- La méthode tient en cinq temps, et l'ordre compte : cadrer, contrôler, construire, mesurer, rendre rejouable.
- Le cadrage se fait avant le SQL et ne se rattrape pas après.
- Les contrôles de qualité précèdent les mesures. Ils coûtent dix minutes et décident si le reste vaut quelque chose.
- Une ligne de `dbo.FactInternetSales` est un article, pas une commande. Compter des commandes au grain article demande un `COUNT(DISTINCT ...)`.
- Sommer une mesure de commande au grain article la compte autant de fois qu'il y a d'articles. C'est la faute la plus fréquente du module.
- On optimise après avoir vérifié l'exactitude, jamais avant.
- Un rapport juste qu'on ne peut pas relancer sans le casser n'est pas un livrable.
- La note de cadrage est le livrable qu'on oublie et celui qui vaut le plus six mois plus tard.
- Un chiffre sans définition n'est pas un chiffre, c'est une source de discussions.

- Les deux critères d'évaluation sont l'exactitude démontrée et la capacité à défendre chaque choix.
 - L'orchestration, la restitution et l'administration de la plateforme vivent dans les formations Analytics Engineering et Snowflake. Ce module reste sur le langage.
-

Exercices

Les exercices de ce module et leur corrigé vivent dans `Exercices_corrige_12.md`. Ils supposent le laboratoire terminé, et ils portent moins sur le SQL que sur les décisions que vous avez prises en l'écrivant.