

Table des matières

SQL avancé — Formation..... 1

 L’ordre des modules est un choix 1

 Le double chemin OLTP/OLAP 2

 Ce que la formation demande de temps 2

 Place dans le parcours 3

 Prérequis 3

 La pile, rangée 4

 Parcours des modules 4

 État d’avancement 9

 Organisation des fichiers..... 9

 Outillage 10

 Publication 10

SQL avancé — Formation

Formation **SQL avancé pour le développeur et l’analyste de données**, sous forme de supports Markdown. Douze modules progressifs, du modèle relationnel jusqu’à l’analytique appliquée. Le fil conducteur : partir des bases (SELECT, JOIN, GROUP BY), sans rien supposer d’acquis, et monter, module après module, jusqu’aux outils que les recruteurs testent vraiment.

L’objectif est **formatif** : passer d’un SQL « qui marche » à un SQL rigoureux et performant, celui qu’on assume en entretien technique et qu’on tient en production.

L’ordre des modules est un choix

La formation vise un profil précis, celui d’ingénieur analytique, et son ordre le reflète. Tout ce qui sert à répondre à une question analytique vient d’abord ; le fonctionnement interne du moteur vient ensuite, sans être sacrifié pour autant.

Partie	Cours	Ce qu’elle contient	Peut-on la différer ?
A. Le SQL de l’analyse	01 à 09	exprimer une question et obtenir une réponse juste	non, c’est le cœur du métier visé

Partie	Cours	Ce qu'elle contient	Peut-on la différer ?
B. Le SQL du moteur	10 et 11	comprendre ce que la machine fait de votre requête	oui, sans se pénaliser sur le court terme
C. La synthèse	12	un cas complet qui remobilise la partie A, et ce qui se transpose de la B	c'est l'aboutissement

Rien n'a été retiré. La partie B contient du SQL réel et utile, les index et les transactions ; elle est simplement placée après ce qui sert tous les jours à un analyste, au lieu de barrer la route. Quelqu'un qui s'arrête à la fin de la partie A a déjà ce qu'il faut pour travailler.

Le double chemin OLTP/OLAP

C'est le parti pris central de cette formation, et ce qui la distingue d'un cours de SQL ordinaire. Un langage ne se comprend pas sur un seul terrain : à partir du **Cours 02**, chaque module a **deux laboratoires** qui posent les mêmes questions sur deux schémas opposés.

Voie	Moteur	Base	Ce qu'elle enseigne
OLAP	DuckDB	adventureworksdw.duckdb, schéma dbo, en étoile	l'analytique telle qu'elle se pratique : le contexte est déjà rassemblé autour du fait
OLTP	PostgreSQL	Adventureworks, portage lorint, normalisée	le même calcul, mais en reconstituant le contexte à chaque requête

Les deux moteurs sont locaux, gratuits et sans compte à ouvrir. Là où une grande plateforme change le geste, un encadré « Portabilité » le dit dans le cours ; la plateforme elle-même est le sujet de la formation *Snowflake (SnowPro Core)*.

La théorie, elle, reste **unique** : le langage ne change pas d'un monde à l'autre. Les exercices et leur corrigé sont **communs** aux deux voies, les énoncés pratiques étant marqués [OLTP] ou [OLAP] quand ils visent un terrain précis.

Le double chemin couvre **toute la partie A à partir du Cours 02**, soit les cours 02 à 09. La règle est simple à retenir : les modules qui apprennent à poser une question ont deux terrains, ceux qui appartiennent en propre à un monde n'en ont qu'un. Le Cours 10 (index) et le Cours 11 (transactions) sont OLTP par nature, le Cours 12 (capstone) est OLAP par nature. Le Cours 00 (installation) et le Cours 01 (fondations) précèdent l'ouverture du double chemin.

Ce que la formation demande de temps

Environ **106 heures** en tout, corrigés compris, pour les treize modules. C'est le chiffre à avoir en tête avant de commencer : à cinq heures par semaine, la formation tient un semestre ; à quinze, elle tient deux mois.

Ce qu'on fait	Temps
Lire les douze théories	16 h 30
Faire les vingt et un laboratoires	24 h 15
Répondre aux 507 énoncés d'exercices	49 h 15
Lire les treize corrigés	16 h 15
Tout	106 h

Deux chemins plus courts existent, et ils sont légitimes. Qui vient chercher le langage et la pratique, sans se mesurer aux énoncés, en a pour 40 h 45 : la théorie et les labos. Et qui ne suit qu'une seule voie du double chemin économise une dizaine d'heures sur les labos des Cours 02 à 09, la voie OLAP en pesant 9 h 30 et la voie OLTP 11 h. Le contraste entre les deux terrains est la matière de cette formation : ne sacrifiez la seconde voie que si le temps l'impose.

D'où viennent ces chiffres. Ils ne sont ni devinés ni repris d'un autre cours : chaque support est mesuré, et un modèle à trois termes convertit la mesure en temps. La prose se lit à 3 800 mots à l'heure, le SQL se tape à 300 lignes à l'heure, lancement et lecture du résultat compris, et chaque énoncé coûte un temps selon sa famille, auquel les questions pratiques et les diagnostics ajoutent la frappe de leur solution. Deux durées échappent au modèle et sont dites telles quelles : le Labo 00 installe, et sa durée est chronométrée sur un lecteur débutant ; le Labo 12 est le capstone, et il se conçoit autant qu'il se tape. Le modèle et son outil sont décrits dans `STYLE.md`, section 7 : recomptez si vous voulez, le calcul se rejoue.

Ce sont des ordres de grandeur, pas des promesses. Un lecteur qui connaît déjà un autre dialecte ira plus vite sur les Cours 02 et 03 ; un débutant complet ira plus lentement partout.

Place dans le parcours

SQL avancé est une des deux fondations du parcours `Data_Domain/`, hors séquence : les formations métier la nomment comme prérequis et y renvoient plutôt que de réécrire le langage. L'autre fondation est *Snowflake (SnowPro Core)*, qui tient la plateforme. La séquence des sept formations métier, de Data Engineering à Architecture et Gouvernance, est décrite dans `Data_Domain/README.md`.

On reste donc ici sur le langage : la formation n'enseigne ni l'administration d'un moteur ni l'exploitation d'une plateforme, elle s'en sert comme terrains. Ce que chaque formation du parcours lui emprunte est inventorié dans `Data_Domain/prerequis/`.

Prérequis

- Aucun prérequis de langage : la formation part de zéro. Le Cours 01 pose le modèle relationnel et l'ordre d'exécution, puis les Cours 02 et 03 font le tour du langage, lire puis écrire.

- Un poste monté selon Data_Domain/GUIDE_INSTALLATION.md, qui installe DuckDB (étape 4) et PostgreSQL (étape 8). Le Cours 00 n'installe rien : il charge les données des deux terrains.
- Les écarts entre moteurs sont traités par un encadré « Portabilité » dans chaque cours, là où la syntaxe diverge. La règle qu'ils suivent : ce qui est affirmé d'un moteur a été lancé sur lui, ou cite sa documentation ; à défaut, l'encadré donne la règle de choix et la forme normalisée, qui est celle qui voyage.

La pile, rangée

Outil	Ce qu'il apprend ici	Statut	Ce qu'il demande au poste	Ce qu'on perd à le sauter
DuckDB	tout le SQL analytique : fenêtrage, CTE, pivots, semi-structuré, séries temporelles	incontournable, dès le Cours 01	rien qui tourne en continu ; 83 Mo de fichiers reçus, 25 Mo pour l'entrepôt monté	la formation entière
PostgreSQL	le même langage sur un schéma normalisé, puis les index, les plans et les transactions	incontournable, dès le Cours 02	un service en continu ; 112 Mo pour la base chargée	la voie OLTP des Cours 02 à 09, et les Cours 10 et 11 en entier
Un client SQL : pgAdmin, DBeaver ou psql	rien ; c'est du confort	au choix, côté PostgreSQL	quelques centaines de Mo pour pgAdmin ou DBeaver	rien : psql est livré avec le moteur
Ruby	rien ; il ne sert qu'à préparer les fichiers du portage	facultatif, voie A du chargement OLTP	une installation de quelques minutes	rien, si vous prenez la voie B
Docker, dans WSL 2	rien ; il ne sert qu'à charger la base OLTP sans Ruby	facultatif, voie B du chargement OLTP	l'étape 5 du guide d'installation	rien, si vous prenez la voie A

Les deux dernières lignes sont deux chemins vers le même résultat, pas deux étapes : on en prend un.

Parcours des modules

Chaque module vit dans son propre dossier Cours_NN_Titre/.

#	Dossier du cours	Module	Durée	Objet
0	Cours_00_Installation/	Mise en place	5 h	AdventureWorks DW monté dans DuckDB par script (requis dès le Cours 01) ;

#	Dossier du cours	Module	Durée	Objet
				AdventureWorks OLTP chargé dans PostgreSQL (requis dès le Cours 02). Une seule fois.
		Partie A. Le SQL de l'analyse		
1	Cours_01_Paysage_SQL_et_modele_relationnel/	Paysage SQL et modèle relationnel	8 h	Cinq mots à distinguer (data, database, DBMS, RDBMS, SQL) ; les cinq familles de commandes ; le paysage des moteurs ; clés primaires et étrangères ; l'étoile et les autres modèles (flocon, 3NF, table large, Data Vault) ; l'ordre d'exécution ; les jointures et le piège du LEFT JOIN ; NULL.
2	Cours_02_Le_langage_SQL/	Le langage SQL : lire et calculer	10 h	L'anatomie d'une requête, les filtres, CASE, les types et les conversions, le texte, les dates, les agrégats et les règles du GROUP BY.
3	Cours_03_Ecrire_dans_la_base/	Écrire dans la base : DML et DDL	11 h	CREATE TABLE, types et contraintes, INSERT, UPDATE, DELETE, MERGE, les vues, et ce

#	Dossier du cours	Module	Durée	Objet
				qui s'annule ou non dans une transaction.
4	Cours_04_Fonctions_de_fenetrage/	Fonctions de fenêtrage	7 h 30	OVER, PARTITION BY, ORDER BY ; ROW_NUMBER, RANK, DENSE_RANK, NTILE ; LAG et LEAD ; cumuls et moyennes mobiles ; les cadres ROWS contre RANGE ; QUALIFY, sur l'entrepôt. Le module phare.
5	Cours_05_CTE_et_recursive/	CTE et récursivité	9 h	WITH, le chaînage lisible, les CTE récursives (séries générées, organigramme côté entrepôt, nomenclature de fabrication côté transactionnel), et les pièges de matérialisation.
6	Cours_06_Agregation_avancee_et_pivots/	Agrégation avancée et pivots	8 h 30	GROUPING SETS, ROLLUP, CUBE, GROUPING(), agrégats conditionnels, FILTER, PIVOT et UNPIVOT, et ce qu'on fait quand PIVOT n'existe pas. Le SQL du reporting.

#	Dossier du cours	Module	Durée	Objet
7	Cours_07_Sous_requetes_correlation_et_ensembles/	Sous-requêtes, corrélation et ensembles	7 h	Sous-requêtes corrélées, EXISTS, IN, ANY, ALL, UNION, INTERSECT, EXCEPT, et les jointures LATERAL.
8	Cours_08_Donnees_semi_structurees/	Données semi-structurées	7 h 30	Le JSON en base : jsonb (PostgreSQL) et le type JSON (l'entrepôt) ; extraire avec les deux flèches, aplatir (jsonb_array_elements, JSON_EACH), typer, indexer le semi-structuré.
9	Cours_09_Series_temporelles_et_as_of_joins/	Séries temporelles et as-of joins	10 h	Le grain temporel et les trous ; variations et rendements ; les cadres en intervalle de temps contre les cadres en lignes ; rééchantillonnage et agrégation par période ; l' as-of join (LATERAL côté PostgreSQL, ASOF LEFT JOIN côté entrepôt) ; îlots et lacunes ; quantiles, déciles et cohortes.
		Partie B. Le SQL du moteur		
10	Cours_10_Index_et_optimisation/	Index, plans d'exécution et optimisation	7 h 30	Index B-tree, composites et couvrants ; lire un plan

#	Dossier du cours	Module	Durée	Objet
				avec EXPLAIN (ANALYZE) ; la sargabilité ; quand un index aide, quand il nuit, et comment un entrepôt optimise sans index, par le rangement physique et l'élagage.
11	Cours_11_Transactions_et_concurrence/	Transactions et concurrence	7 h	ACID, les niveaux d'isolation, les anomalies, les verrous et le MVCC de PostgreSQL.
		Partie C. La synthèse		
12	Cours_12_SQL_analytique_applique/	SQL analytique appliqué (capstone)	8 h 30	Un cas complet mené du chargement au rapport : modéliser, transformer, mesurer ce que la requête coûte, rendre le tout rejouable. Remobilise les neuf modules de la partie A, et ce qui se transpose de la partie B : la sargabilité, la lecture d'un profil d'exécution, l'atomicité et l'idempotence d'un chargement.

Ce qui vient après. Le réglage fin d'un moteur donné (partitionnement, vues matérialisées, réplication) et l'orchestration (dbt, entrepôts cloud) prolongent ce parcours, mais vivent dans les formations Snowflake et Analytics Engineering plutôt que dans celle-ci.

État d'avancement

Cours	Théorie	Labos	Exercices et corrigé
00 Installation	sans objet	fait	fait
01 Paysage SQL	fait	fait (un seul terrain)	fait
02 Le langage SQL	fait	fait (OLTP et OLAP)	fait
03 Écrire dans la base	fait	fait (OLTP et OLAP)	fait
04 Fonctions de fenêtrage	fait	fait (OLTP et OLAP)	fait
05 CTE et récursivité	fait	fait (OLTP et OLAP)	fait
06 Agrégation avancée	fait	fait (OLTP et OLAP)	fait
07 Sous-requêtes et ensembles	fait	fait (OLTP et OLAP)	fait
08 Données semi-structurées	fait	fait (OLTP et OLAP)	fait
09 Séries temporelles	fait	fait (OLTP et OLAP)	fait
10 Index et optimisation	fait	fait (OLTP seul)	fait
11 Transactions	fait	fait (OLTP seul)	fait
12 Capstone	fait	fait (OLAP seul)	fait

Les douze modules sont rédigés, et le linter compte 59 supports, tous au vert.

La voie analytique a changé de moteur : elle tournait sur Snowflake, elle tourne sur DuckDB, sur un entrepôt monté par script. La reprise des douze cours est finie le 2026-09-19. Snowflake reste en encadrés « Portabilité », d'après sa documentation (D117).

Organisation des fichiers

Un dossier par cours, qui réunit la théorie, le ou les laboratoires, l'énoncé d'exercices et son corrigé.

Élément	Rôle	Devenir
Theorie_NN.md	ce qu'on lit : concepts, exemples, points clés	→ Theorie_NN.docx

Élément	Rôle	Devenir
Labo_NN_OLAP.md	ce qu'on fait sur l'entrepôt	→ .docx et .sql
Labo_NN_OLTP.md	les mêmes questions sur le transactionnel	→ .docx et .sql
Exercices_NN.md	les énoncés, sans aucune solution	→ .docx
Corrige_NN.md	les réponses, dans un fichier séparé	→ .docx

Chaque théorie suit la même trame : **Objectifs, Théorie** (sections numérotées, dont une section « Sur les deux terrains » quand le cours en a deux), **Points clés à retenir**, puis le renvoi vers les **Exercices**. Toute la manipulation est dans les labos, toutes les questions dans l'énoncé d'exercices, toutes les réponses dans le corrigé.

Les exercices comptent une quarantaine de questions par cours, réparties en cinq familles : courtes, pratiques, diagnostics, à développer, mises en situation. Les conventions complètes sont dans `STYLE.md`.

Outillage

Chaîne d'édition commune à toutes les formations iAlexMG : `.md` (le maître, versionné) → `.docx` (ce que le lecteur reçoit).

À la première ouverture d'un `.docx`. Le sommaire et les numéros de page sont des champs Word : ils arrivent vides. Sélectionnez tout, Ctrl+A, puis appuyez sur F9 et choisissez « Mettre à jour toute la table ». Word les tient à jour ensuite, et les recalcule à chaque impression.

- `lint_md.py` — vérifie mécaniquement les règles de `STYLE.md` sur tous les supports. `python lint_md.py`, à lancer avant chaque commit. L'objectif est zéro erreur et zéro avertissement.
- `md_vers_docx.py` — convertit chaque `Theorie_NN.md`, `Labo_NN*.md`, `Exercices_NN.md` et `Corrige_NN.md` en `.docx` via Pandoc et le gabarit Word partagé `Formations/_commun/word_template.docx`, commun à toutes les formations (paysage, marges étroites de 0,5 po, pour loger les tables de résultats et les plans EXPLAIN sans les tasser ; sommaire et numéros de page). Le gabarit est versionné, et `_commun/gabarit_word.py` le refabrique. `python md_vers_docx.py` ne refait que ce qui en a besoin, `--force` refait tout.
- `monter_entrepot_dw.sql` (dans `Cours_00_Installation/`) — monte l'entrepôt d'un seul trait : il crée le schéma `dbo` et les huit tables aux bons noms, y verse les fichiers de Microsoft, puis affiche les comptes de contrôle. Une seconde, 25 Mo.

Prérequis : Pandoc 3.1 ou plus, et `pip install -r requirements.txt`. Environnement conda `formations`.

On n'édite jamais un `.docx` à la main : c'est une sortie générée, et le polissage serait perdu à la régénération suivante. Toute correction se fait dans le `.md`.

Publication

Ce que le lecteur reçoit est le .docx, avec son sommaire et ses numéros de page (décision D109 du parcours). L'export PDF a été coupé le 2026-09-19, avec son outil ; la question se rouvrira le jour où une formation sera publiée sur le site.

Le dépôt d'atelier étant privé, les .md et les .docx y sont versionnés : GitHub affiche les premiers dans le navigateur, et le .docx se télécharge pour se lire dans Word sur un téléphone. Les jeux de données AdventureWorks (174 Mo reçus de Microsoft, 83 pour l'entrepôt et 91 pour le transactionnel), les bases montées et les sauvegardes locales, eux, ne sont pas versionnés : tout se remonte par le script du Cours 00.