

04 — Inférence bayésienne

Table des matieres

[3.1 — A priori, vraisemblance, posterior](#)

[3.2 — Conjugaison Beta-Bernoulli](#)

[3.3 — Intervalle crédible \(vs intervalle de confiance\)](#)

[Réponses aux exercices](#)

Niveau : avancé. **Prérequis** : 01_fondations.md (Bernoulli, $p = 6/49$), 02_lois_de_probabilite.md (§1.1 binomiale, §1.6 loi Beta & conjugaison), 03_inference_frequentiste.md (§2.1 H_0 , §2.7 intervalle de confiance). **Couvre les fiches source** : 3.1 à 3.3 de concepts_FR.md. **Documents suivants** : 06_tests_phase1.md (les tests appliqués mobilisent ces outils).

Idée directrice. Là où le fréquentiste (document 03) demande « *à quel point mes données seraient surprenantes si le hasard était vrai ?* », le bayésien retourne la question : « *vu mes données, que dois-je croire sur la probabilité de sortie de chaque numéro ?* ». On part d'une **croissance** (a priori), on la confronte aux **données** (vraisemblance), on obtient une croissance révisée (posterior). Pour le Lotto, grâce à la conjugaison Beta-Bernoulli, cette révision est une simple **addition de compteurs**, et elle livre des **intervalles crédibles** — l'objet que le profane attribue, à tort, à l'intervalle de confiance.

3.1 — A priori, vraisemblance, posterior

En une phrase

Le théorème de Bayes met à jour une croissance : $posterior \propto vraisemblance \times a\ priori$ — on part d'une opinion sur p , les données la corrigent.

Intuition

Apprendre, c'est réviser une opinion à la lumière des faits. Avant de voir le moindre tirage, j'ai une croissance sur la probabilité de sortie d'un numéro (par exemple « je n'en sais rien, ça peut être n'importe quoi entre 0 et 1 »). Chaque tirage observé déplace cette croissance : si le numéro sort souvent, ma croissance se concentre vers des valeurs plus hautes ; sinon, vers des valeurs plus basses. Le posterior est le point d'équilibre entre ce que je croyais et ce que les données disent — et plus les données sont nombreuses, plus elles l'emportent.

Formalisation

Soit θ le paramètre inconnu (ici la probabilité de sortie d'un numéro) et D les données. Le **théorème de Bayes** s'écrit

$$\underbrace{\pi(\theta | D)}_{\text{posterior}} = \frac{\overbrace{P(D | \theta)}^{\text{vraisemblance}} \underbrace{\pi(\theta)}_{\text{a priori}}}{\underbrace{P(D)}_{\text{évidence}}}, \quad P(D) = \int P(D | \theta) \pi(\theta) d\theta.$$

Comme $P(D)$ ne dépend pas de θ (c'est une constante de normalisation), on retient la forme proportionnelle, suffisante pour identifier le posterior :

$$\pi(\theta | D) \propto P(D | \theta) \pi(\theta).$$

Les trois ingrédients :

- **A priori** $\pi(\theta)$: la croyance *avant* les données. *Non informatif* (plat, « ignorance ») ou *informatif* (concentré, expertise). Pour une probabilité, une loi naturelle sur $[0,1]$ est la **Beta** (§1.6).
- **Vraisemblance** $P(D | \theta)$: la probabilité des données *si* θ était la vraie valeur. Pour k sorties sur N tirages (Bernoulli i.i.d.), $P(D | \theta) \propto \theta^k (1 - \theta)^{N-k}$.
- **Posterior** $\pi(\theta | D)$: la croyance *après* les données, qui sert d'a priori à la prochaine mise à jour (apprentissage séquentiel).

Influence vs domination des données. Le posterior est un compromis pondéré entre a priori et vraisemblance. À **petit** N , l'a priori pèse ; à **grand** N , la vraisemblance **domine** et le posterior converge vers l'estimation des données, quel que soit l'a priori (pourvu qu'il n'exclue pas la vraie valeur). C'est le **lavage de l'a priori** : avec $N = 4\,377$, le choix de l'a priori est sans conséquence pratique (§3.2).

Marginalisation. Quand il y a des paramètres de nuisance η , on les **intègre** : $\pi(\theta | D) = \int \pi(\theta, \eta | D) d\eta$. C'est la façon bayésienne de « tenir compte de l'incertitude » sur ce qui ne nous intéresse pas directement.

Dans iAlexMG

- **Étape 2.4 (bayésien)** : θ = probabilité de sortie d'un numéro donné ; a priori Beta(1,1) (uniforme, ignorance) ; vraisemblance binomiale (k sorties sur $N = 4\,377$) ; posterior Beta($1 + k, 1 + N - k$) (§3.2). On obtient une **croyance complète** sur chaque numéro, pas seulement un point.
- Cette croyance se résume par sa moyenne et son **intervalle crédible** à 95 % (§3.3), comparé à 6/49 : tous les posteriors se superposent autour de 6/49 → rien ne distingue les numéros.

Pièges & malentendus

- **Confondre vraisemblance et posterior.** $P(D \mid \theta)$ (fonction de θ à données fixées) n'est pas une loi de probabilité sur θ ; le posterior, oui.
- « **L'a priori rend tout subjectif** ». Son influence est **mesurable** et, à grand N , négligeable. Le déclarer explicitement est une force, pas une faiblesse.
- **Oublier la normalisation.** Travailler en $\propto$ est commode, mais le posterior est bien une densité qui intègre à 1 ; les quantités absolues (évidence) servent à comparer des modèles.
- **Inverser le conditionnement.** $\pi(\theta \mid D) \neq P(D \mid \theta)$ — c'est tout l'apport de Bayes (et l'erreur classique sur la p-value, §2.2).

Pour vérifier ta compréhension

1. Écris la forme proportionnelle du posterior pour k sorties sur N tirages avec un a priori $\pi(\theta)$ quelconque.
2. Pourquoi, à $N = 4\,377$, le choix entre Beta(1,1) et un a priori faiblement informatif change-t-il peu le posterior ?
3. En quoi le posterior d'aujourd'hui peut-il servir d'a priori demain ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Évidence et facteurs de Bayes** : $P(D)$ sert à comparer des modèles entiers (rapport d'évidences), alternative bayésienne au test d'hypothèse.
- **A priori de Jeffreys** : a priori non informatif invariant (Beta($\frac{1}{2}$, $\frac{1}{2}$) pour une proportion).
- **MCMC** : quand il n'y a pas de conjugaison, on échantillonne le posterior (inutile ici, cf. §3.2).

3.2 — Conjugaison Beta-Bernoulli

En une phrase

L'a priori Beta est **conjugué** de la vraisemblance Bernoulli : le posterior reste une Beta, obtenue en **ajoutant les compteurs** de succès et d'échecs aux paramètres.

Intuition

La forme de la croyance ne change pas — elle reste une Beta — seules ses « tailles » bougent. Apprendre se réduit à compter : on ajoute le nombre de sorties à α et le nombre d'absences à β . Pas

d'intégrale, pas de simulation : une addition. C'est ce qui rend le traitement bayésien du Lotto à la fois exact et trivial à calculer pour les 49 numéros.

Formalisation

Résultat (démontré en §1.6). A priori $\theta \sim \text{Beta}(\alpha, \beta)$, données = k succès sur N épreuves Bernoulli. Alors

$$\pi(\theta | D) \propto \underbrace{\theta^k (1 - \theta)^{N-k}}_{\text{vraisemblance}} \cdot \underbrace{\theta^{\alpha-1} (1 - \theta)^{\beta-1}}_{\text{a priori}} = \theta^{(\alpha+k)-1} (1 - \theta)^{(\beta+N-k)-1},$$

soit

$$\boxed{\theta | D \sim \text{Beta}(\alpha + k, \beta + N - k).}$$

Pseudo-observations. α et β agissent comme des **succès et échecs fictifs** ajoutés avant les vraies données. Beta(1,1) (uniforme) équivaut à « 1 succès et 1 échec imaginaires ». La **moyenne a posteriori**,

$$\mathbb{E}[\theta | D] = \frac{\alpha + k}{\alpha + \beta + N},$$

est une moyenne pondérée entre l'a priori $\frac{\alpha}{\alpha+\beta}$ et la fréquence observée $\frac{k}{N}$, le poids des données croissant avec N .

Lien avec le lissage de Laplace. Avec Beta(1,1), la moyenne a posteriori vaut $\frac{k+1}{N+2}$: exactement le **lissage de Laplace** (ajouter 1 à chaque compte). Le bayésien *justifie* cette recette empirique comme une moyenne a posteriori sous a priori uniforme.

Lavage de l'a priori. Quand $N \rightarrow \infty$, $\mathbb{E}[\theta | D] \rightarrow k/N$ et la variance du posterior $\rightarrow 0$: les compteurs de données écrasent α, β .

Dans iAlexMG

- **Étape 2.4** : pour chaque numéro, posterior Beta(1 + k , 1 + $N - k$) calculé en **une addition**, sans MCMC.
- Exemple chiffré : un numéro sorti $k = 536$ fois sur $N = 4\,377$ donne Beta(537, 3842), de moyenne $537/4379 \approx 0,1226$ — pratiquement $6/49 \approx 0,1224$.

Pièges & malentendus

- **Croire qu'il faut simuler.** La conjugaison rend le posterior **analytique** ; MCMC est inutile ici.
- **A priori trop informatif à petit N .** Sur peu de données, un a priori mal choisi biaise le posterior ; à $N = 4\,377$, le risque s'évanouit.

- **Confondre $\mathbb{E}[\theta \mid D]$ et le maximum de vraisemblance k/N .** Ils diffèrent par l'a priori (les pseudo-observations) ; ils convergent à grand N .

Pour vérifier ta compréhension

1. A priori Beta(1,1), un numéro sort $k = 500$ fois sur $N = 4\,377$. Donne le posterior et sa moyenne.
2. Montre que la moyenne a posteriori sous Beta(1,1) est $\frac{k+1}{N+2}$ (lissage de Laplace).
3. Pourquoi n'a-t-on pas besoin de MCMC pour ces posteriors ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Conjugaison Dirichlet-multinomiale** : version multivariée, si l'on modélisait conjointement les 49 probabilités sous la contrainte $\sum p_i = 1$.
- **A priori conjugués en famille exponentielle** : la conjugaison Beta-Bernoulli est un cas d'un cadre général.

3.3 — Intervalle crédible (vs intervalle de confiance)

En une phrase

L'intervalle crédible à 95 % contient le paramètre avec une probabilité de 95 % **vu les données** — une affirmation directe sur θ , exactement ce que l'intervalle de confiance (§2.7) ne dit *pas*.

Intuition

Enfin l'énoncé que le profane croit (à tort) entendre quand on lui parle d'intervalle de confiance : « il y a 95 % de chances que la vraie probabilité du 7 soit dans cet intervalle ». En bayésien, cette phrase est **correcte**, parce que θ y est traité comme une quantité incertaine dotée d'une loi (le posterior). On découpe simplement le posterior pour isoler 95 % de sa masse.

Formalisation

Un **intervalle crédible** à $1 - \alpha$ est un intervalle $[a, b]$ tel que, **vu les données**,

$$P(a \leq \theta \leq b \mid D) = 1 - \alpha,$$

la probabilité portant sur θ (via le posterior), les bornes étant fixées par les données. Deux constructions usuelles :

- **Equal-tailed (à queues égales)** : on coupe $\alpha/2$ de masse de chaque côté, soit les **quantiles** $\frac{\alpha}{2}$ et $1 - \frac{\alpha}{2}$ du posterior. Pour un posterior $\text{Beta}(\alpha', \beta')$, ce sont directement les quantiles de la loi Beta. Simple, invariant par reparamétrisation monotone.
- **HPD (highest posterior density)** : le **plus court** intervalle contenant $1 - \alpha$ de la masse ; toute valeur dedans a une densité $\geq$ à toute valeur dehors. Plus naturel pour un posterior asymétrique, mais non invariant par reparamétrisation. Pour un posterior symétrique, HPD = equal-tailed.

Exemple chiffré (numéro à $k = 536$, $N = 4\,377$). Posterior $\text{Beta}(537, 3842)$, moyenne $\approx 0,1226$, écart-type $\approx 0,00495$. L'intervalle crédible equal-tailed à 95 % vaut $\approx [0,113, 0,132]$ — il **contient** $6/49 \approx 0,1224$. Conclusion bayésienne directe : « il y a 95 % de probabilité que la vraie probabilité de ce numéro soit dans cet intervalle, lequel englobe $6/49$ ».

L'opposition fine avec l'intervalle de confiance (§2.7) :

	Intervalle de confiance (fréquentiste)	Intervalle crédible (bayésien)
Objet aléatoire	les bornes (via les données)	le paramètre θ (via le posterior)
Énoncé	« 95 % des intervalles <i>ainsi construits</i> couvrent θ »	« $P(\theta \in [a, b] \mid D) = 0,95$ »
Sur cet intervalle	pas de probabilité attachée à θ	probabilité directe sur θ
Ingrédient en plus	aucun a priori	un a priori

Numériquement, avec un a priori plat et un grand N , les deux intervalles **coïncident presque** — mais leur **interprétation** reste radicalement différente.

Dans iAlexMG

- **Figure 10** : intervalles **crédibles** à 95 % par numéro (issus des posteriors $\text{Beta}(1 + k, 1 + N - k)$), comparés à $6/49$. Tous l'englobent $\rightarrow$ aucun numéro ne se distingue.
- Le projet **juxtapose** crédible (ici) et confiance (T1, §2.7) pour faire sentir que des nombres quasi identiques racontent deux histoires épistémiques opposées.

Pièges & malentendus

- **Plaquer l'interprétation crédible sur un IC de confiance.** L'erreur que tout ce chapitre vise à corriger : seul le crédible autorise « 95 % de probabilité que θ soit ici ».

- **Croire HPD = equal-tailed toujours.** Vrai seulement si le posterior est symétrique ; pour une Beta très asymétrique (numéro à faible k), ils diffèrent.
- **Oublier la dépendance à l'a priori à petit N .** L'intervalle crédible *hérite* de l'a priori ; à grand N il s'efface, à petit N non.

Pour vérifier ta compréhension

1. Formule l'énoncé correct pour un intervalle crédible à 95 % de la probabilité du 7. En quoi diffère-t-il du même énoncé pour un IC de confiance ?
2. Pour le posterior Beta(537,3842), comment obtient-on concrètement les bornes equal-tailed à 95 % ?
3. Quand HPD et equal-tailed coïncident-ils ? Quand diffèrent-ils nettement ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Calibration des intervalles crédibles** : sous a priori « correct », un crédible à 95 % a aussi une couverture fréquentiste proche de 95 % (matching priors).
- **Régions crédibles multivariées** : HPD en dimension > 1 (ellipses/contours du posterior).
- **Décision bayésienne** : au-delà des intervalles, minimiser une perte attendue a posteriori (lien avec les règles de score propres, §5.4).

Réponses aux exercices

3.1

1. $\pi(\theta | D) \propto \theta^k (1 - \theta)^{N-k} \pi(\theta)$: la vraisemblance binomiale fois l'a priori, à une constante de normalisation près.
2. Parce qu'à grand N la **vraisemblance domine** : les compteurs de données ($k, N - k$) écrasent les pseudo-observations de l'a priori (α, β), et le posterior converge vers l'estimation des données quel que soit l'a priori (lavage de l'a priori).
3. Le posterior résume toute l'information acquise ; pour de nouvelles données, il **devient l'a priori** et on lui réapplique Bayes — mise à jour séquentielle cohérente.

3.2

1. Posterior $\text{Beta}(1 + 500, 1 + 4377 - 500) = \text{Beta}(501, 3878)$. Moyenne = $501/(501 + 3878) = 501/4379 \approx 0,1144$.
2. Sous $\text{Beta}(1,1)$: $\mathbb{E}[\theta \mid D] = \frac{\alpha+k}{\alpha+\beta+N} = \frac{1+k}{1+1+N} = \frac{k+1}{N+2}$ — le lissage de Laplace.
3. Parce que la **conjugaison** donne le posterior sous forme **analytique** ($\text{Beta}(\alpha + k, \beta + N - k)$) : moyenne, variance et quantiles se calculent directement, sans échantillonnage.

3.3

1. Crédible : « il y a **95 % de probabilité** que la vraie probabilité du 7 soit dans $[a, b]$, vu les données ». IC de confiance : « **95 % des intervalles** construits par cette procédure contiendraient la vraie probabilité » — aucune probabilité attachée à cet intervalle-ci.
2. On prend les **quantiles** 2,5 % et 97,5 % de la loi $\text{Beta}(537, 3842)$ (p. ex. `scipy.stats.beta.ppf([0.025, 0.975], 537, 3842)`).
3. Ils **coïncident** quand le posterior est **symétrique** (ici, Beta quasi symétrique car $\alpha' \approx$ grand et la moyenne loin de 0/1) ; ils **diffèrent** pour un posterior **asymétrique** (numéro à très faible k , Beta penchée), où le HPD est plus court et décalé vers le mode. ``