

08 — La cascade binaire (n-grammes)

Table des matieres

[6.1 — Représentation binaire de l’historique](#)

[6.2 — Diagnostic n-grammes \(test sériel\)](#)

[6.3 — Prédicteur « déficit \$\Rightarrow\$ dû » & réversion à la moyenne](#)

[6.4 — Convergence n’est pas force de rappel](#)

[Réponses aux exercices](#)

Niveau : base $\rightarrow$ avancé. **Prérequis** : 01_fondations.md (Bernoulli, espérance/variance, LGN), 02_lois_de_probabilite.md (§1.1 binomiale, §1.7 n-grammes), 03_inference_frequentiste.md (§2.9 permutation), 05_biais_cognitifs.md (§7.1 mythe du numéro en retard), 07_apprentissage_automatique.md (§5.4 log-loss, §5.5 plancher). **Couvre les fiches source** : 6.1 à 6.4 de concepts_FR.md. **Source des chiffres** : reports/phase2_ml_FR.md (§2.5, figure fig11).

Idée directrice. La cascade binaire est le modèle proposé par Alex : il **formalise le mythe du numéro en retard** puis le **réfute sur les données**, en un seul dispositif à deux volets. Volet A — un **diagnostic** (test sériel) cherche une structure dans les motifs de bits ; il n’en trouve aucune. Volet B — un **prédicteur** encode honnêtement la règle « un motif en déficit est dû » ; sa log-loss hors-échantillon **monte** avec la longueur des motifs. La raison profonde tient en une phrase, §6.4 : *la convergence n’est pas une force de rappel*.

6.1 — Représentation binaire de l’historique

En une phrase

Chaque numéro devient une **séquence de bits** (0 absent, 1 tiré) le long des tirages — son « code-barres » temporel — entrée commune du diagnostic et du prédicteur.

Intuition

Pour analyser la mémoire d’un numéro, on le réduit à l’essentiel : une suite de 0 et de 1. Le numéro 17 devient ...0 1 0 0 1 0..., où chaque 1 marque un tirage où il est sorti. Cette représentation minimale permet de chercher des motifs (paires, triplets) et de tester si le passé prédit l’avenir.

Formalisation

Pour le numéro j , on définit la séquence binaire $(b_{t,j})_{t=1}^N$ avec $b_{t,j} = \mathbf{1}\{j \text{ tiré au tirage } t\}$. C'est exactement l'indicatrice du processus de Bernoulli (§0.1), vue comme une **chaîne de bits**. Empilées sur les 49 numéros, ces séquences forment une **matrice multi-hot** $B \in \{0,1\}^{N \times 49}$ (la même que celle du LSTM, §5.13), soumise à la **contrainte structurelle** : chaque ligne (tirage) contient **exactement 6 uns** (tirage sans remise, §0.3).

$$\sum_{j=1}^{49} b_{t,j} = 6 \quad \text{pour tout } t.$$

La fréquence marginale de 1 dans une colonne est $\approx p = 6/49$.

Dans iAlexMG

Cette représentation est l'**entrée commune** des deux volets de l'étape 2.5 : le diagnostic n-grammes (§6.2) compte les motifs de bits ; le prédicteur « déficit $\Rightarrow$ dû » (§6.3) lit le taux récent de 1 pour parier sur le bit suivant.

Pièges & malentendus

- **Oublier la contrainte « 6 uns par ligne »**. Les colonnes ne sont pas indépendantes au sein d'un tirage (corrélation $-1/48$, §0.3) ; pertinent pour calibrer la loi nulle.
- **Confondre lignes et colonnes**. Une *colonne* = l'histoire temporelle d'un numéro ; une *ligne* = la composition d'un tirage.

Pour vérifier ta compréhension

1. Que représente une colonne de la matrice B ? Une ligne ?
2. Quelle est la fréquence attendue de 1 dans une colonne, et pourquoi ?
3. Pourquoi chaque ligne contient-elle exactement 6 uns ?

(Réponses [à la fin](#).)

Pour aller plus loin

- **Encodage multi-hot** (§5.13) : même objet, vu côté réseau récurrent.
- **Suites binaires & tests d'aléa** : la porte d'entrée des tests NIST (§1.7).

6.2 — Diagnostic n-grammes (test sériel)

En une phrase

On compte les motifs de n bits observés vs attendus sous i.i.d., avec une p-value par **permutation** ; si une mémoire existait, certains motifs dévièrent de leur quota.

Intuition

Un seul bit, c'est la fréquence (T1). Mais une mémoire pourrait se cacher dans des **enchaînements** : « après deux absences, plus de présences ». On compte donc les paires 00, 01, 10, 11, les triplets, etc., et on compare au quota du pur hasard. Aucun écart = aucune structure temporelle, à aucun ordre.

Formalisation

H₀ : les bits sont i.i.d. — chaque motif de n bits apparaît à sa fréquence théorique $p^a(1-p)^b$ (aucune mémoire d'ordre n). **H₁** : au moins un motif s'écarte de son quota (structure temporelle d'ordre n).

Pour un motif de n bits avec a uns et $b = n - a$ zéros, la probabilité sous i.i.d. est $p^a(1-p)^b$ (§1.7). On compte les occurrences observées (fenêtres glissantes) et on les compare aux attendues. **Problème** : les fenêtres **chevauchantes** corréler les comptes, ce qui invalide un χ^2 naïf (§1.7). **Solution** : p-value par **test de permutation** (§2.9) — on remélange l'ordre temporel (préservant la fréquence marginale, détruisant toute structure), ce qui gère exactement le chevauchement.

Dans iAlexMG (résultats)

Volet A — diagnostic. Fréquences de blocs observées vs attendues, p-value par permutation :

n bits	2	3	4	5
permutation p	0,83	0,80	0,72	0,36

Tous $\gg 0,05$: **aucune structure de bloc**. Les motifs **collent au théorique** (figure 11a). C'est une belle généralisation de T1 (1 bit = fréquence) jusqu'au test sériel multi-bits.

Pièges & malentendus

- **χ^2 sur fenêtres chevauchantes.** Comptes corrélés $\rightarrow$ p-value fausse ; utiliser la permutation.
- **Tester beaucoup de n sans correction.** Multiplicité (§2.5) ; ici les p sont toutes très élevées, le problème ne se pose pas.
- **Rare $\neq$ anormal.** Un motif long est intrinsèquement rare ; seul l'écart à l'attendu compte.

Pour vérifier ta compréhension

1. Pourquoi recourt-on à la permutation plutôt qu'à un χ^2 ?
2. Que conclure de $p = 0,83$ pour les paires ?

3. En quoi ce diagnostic généralise-t-il le Test 1 ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Tests NIST** (block frequency, serial, approximate entropy) : la même famille (§1.7).
 - **Chaînes de Markov d'ordre $n - 1$** : ce que teste implicitement un test sériel d'ordre n .
-

6.3 — Prédicteur « déficit $\Rightarrow$ dû » & réversion à la moyenne

En une phrase

On encode la règle du joueur — « un motif en retard va sortir » — en réversion à la moyenne, de façon causale ; sa log-loss hors-échantillon **monte** avec n : la règle dégrade la prédiction.

Intuition

C'est le mythe du numéro en retard, mis en équation et **exécuté honnêtement**. Si un numéro (ou un motif) est sorti moins que son quota récemment, la règle parie qu'il va « rattraper » : elle mise *contre* la fréquence récente. On la passe dans le harnais d'évaluation OOS (document 07) et on regarde si elle gagne. Elle perd — et de plus en plus à mesure qu'on raffine.

Formalisation

H₀ : la règle « déficit $\Rightarrow$ dû » n'apporte aucun pouvoir prédictif — sa log-loss OOS ne fait pas mieux que le plancher $H(6/49)$ (§5.5). **H₁** : la règle améliore la prédiction (log-loss OOS sous le plancher), c.-à-d. un déficit annonce vraiment une sortie.

La règle « déficit $\Rightarrow$ dû » s'écrit, pour le bit suivant, comme une **réversion à la moyenne** calculée **causalement** (sur l'historique $< t$) :

$$p(\text{suivant} = 1) = \text{clip}(2 p_0 - \hat{r}), \quad p_0 = \frac{6}{49},$$

où $\hat{r}$ est le **taux réalisé** récent du motif. Si $\hat{r} < p_0$ (déficit), la règle prédit $> p_0$ (« il est dû ») ; si $\hat{r} > p_0$, elle prédit $< p_0$. Le clip borne dans $[\varepsilon, 1 - \varepsilon]$ (§5.4). On évalue en log-loss OOS contre le plancher (§5.5).

Dans iAlexMG (résultats)

Volet B — le piège, exécuté. Log-loss OOS de la cascade par longueur de motif :

n bits	1	2	3	4	5
log-loss OOS	0,3718	0,3719	0,3723	0,3730	0,3762

À $n = 1$, la règle dégénère en fréquence ($\approx 6/49$) et **touche le plancher** ; puis la log-loss **monte de façon monotone** (figure 11b) : **plus on applique la logique du déficit, plus on se trompe**. Le test apparié classe la cascade « pire » que le plancher.

Pièges & malentendus

- **Croire qu'un déficit crée une opportunité.** C'est l'erreur même que le modèle réfute : miser contre la fréquence récente **dégrade** la prédiction.
- **Confondre $n = 1$ « au plancher » avec un succès.** À $n = 1$ la règle n'est plus le mythe, juste la fréquence de base.
- **Oublier la causalité.** Le taux réalisé est calculé sur $< t$: aucune fuite (§5.1).

Pour vérifier ta compréhension

1. Que prédit la règle si le taux réalisé récent est inférieur à $6/49$?
2. Pourquoi la log-loss touche-t-elle le plancher à $n = 1$?
3. Que signifie la montée monotone de la log-loss avec n ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Modèle de Markov d'ordre $n - 1$ inversé** : lecture formelle de la règle de réversion.
- **Anti-persistence** : pourquoi parier sur le renversement n'a pas d'edge sous H_0 .
- **Lien §6.4** : la justification théorique de cet échec.

6.4 — Convergence n'est pas force de rappel

En une phrase

La loi des grands nombres fait converger la **proportion** (le dénominateur grandit), pas les **compteurs** : un déficit n'est jamais remboursé — il est dilué.

Intuition

C'est le cœur mathématique du mythe du numéro en retard. Oui, à long terme, la fréquence d'un numéro tend vers 6/49. Mais cela ne veut **pas** dire que le hasard « corrige » un retard : la moyenne se rapproche de sa cible parce qu'on divise par un N de plus en plus grand, pas parce que les sorties manquantes sont rattrapées. *La moyenne se dilue, elle ne se corrige pas.*

Formalisation

Soit $Y_N = \sum_{t=1}^N b_t$ le nombre de sorties d'un numéro sur N tirages.

- **La proportion converge (LGN).** La **loi faible** des grands nombres donne $\hat{p}_N = Y_N/N \xrightarrow{P} p$; la **loi forte** donne la convergence presque sûre. La fréquence s'approche de 6/49.
- **Mais l'écart absolu grandit.** L'écart-type de Y_N est $\sqrt{Np(1-p)}$ (§0.4), donc l'**écart absolu** typique $|Y_N - Np|$ **croît en $\sqrt{N}$** — il ne tend pas vers 0, au contraire. Ce qui tend vers 0, c'est l'**écart relatif** :

$$\frac{|Y_N - Np|}{N} \sim \frac{\sqrt{Np(1-p)}}{N} = \sqrt{\frac{p(1-p)}{N}} \xrightarrow{N \rightarrow \infty} 0.$$

Conséquence décisive. Un « déficit » de compteurs n'est jamais remboursé : il devient simplement négligeable *devant un total qui grandit*. Il n'existe aucun mécanisme de rappel.

Lien martingales. Sous H_0 , $(Y_N - Np)$ est une martingale : son espérance future, sachant le passé, est sa valeur actuelle — formellement, *aucune stratégie fondée sur le passé ne peut créer un avantage*. C'est l'énoncé rigoureux de « le hasard n'a pas de mémoire » (et le théorème d'arrêt interdit tout système de pari gagnant).

Dans iAlexMG

- **Justification théorique de l'échec de §6.3** : la règle « déficit $\Rightarrow$ dû » parie sur un remboursement qui n'arrive jamais, d'où la log-loss qui monte.
- **Cœur du mythe du numéro en retard** (§7.1) : la confusion entre convergence (relative) et compensation (absolue).

Pièges & malentendus

- « **À la fin tout s'équilibre, donc ça se rattrape.** » L'équilibre est une *dilution* (écart relatif $\rightarrow 0$), pas une *compensation* (écart absolu ne diminue pas).
- **Confondre écart absolu et relatif.** Les deux comportements ($\sqrt{N}$ vs $1/\sqrt{N}$) coexistent et ne se contredisent pas (§0.4).
- **Croire à un « système ».** Les martingales interdisent tout avantage fondé sur le passé.

Pour vérifier ta compréhension

1. La fréquence d'un numéro converge vers $6/49$. L'écart absolu $|Y_N - Np|$ converge-t-il vers 0 ? Que fait-il ?
2. Pourquoi peut-on dire « la moyenne se dilue, elle ne se corrige pas » ?
3. Quel objet mathématique formalise « aucune stratégie sur le passé ne donne d'avantage » ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **LGN faible vs forte** : convergence en probabilité vs presque sûre.
 - **Théorème central limite** (§1.4) : décrit *comment* l'écart absolu fluctue (en $\sqrt{N}$).
 - **Martingales & théorème d'arrêt optionnel** : l'impossibilité formelle des systèmes de pari.
-

Réponses aux exercices

6.1

1. Une **colonne** = l'histoire temporelle (le code-barres de bits) d'un numéro donné ; une **ligne** = la composition d'un tirage (quels numéros sont sortis).
2. $\approx 6/49 \approx 0,1224$: c'est la probabilité de sortie d'un numéro à chaque tirage (§0.2).
3. Parce que chaque tirage sélectionne exactement 6 numéros distincts sans remise (§0.3).

6.2

1. Parce que les fenêtres **chevauchantes** rendent les comptes corrélés, ce qui invalide la loi du χ^2 ; la permutation reconstruit la vraie loi nulle (§2.9).
2. Que les paires 00/01/10/11 apparaissent à des fréquences indiscernables du pur hasard : aucune structure d'ordre 2.
3. Le Test 1 examine un seul bit (la fréquence) ; le diagnostic n-grammes étend cette idée aux motifs de longueur n — c'est le test sériel multi-bits.

6.3

1. Elle prédit une probabilité **supérieure** à $6/49$ (« il est en déficit, donc dû »).

2. Parce qu'à $n = 1$ la règle dégénère en estimation de la **fréquence de base** ($\approx 6/49$), qui est précisément la prédiction optimale (le plancher, §5.5).
3. Que **plus on applique la logique du déficit** (motifs plus longs), **plus on s'éloigne de la vérité** : la stratégie du joueur dégrade activement la prédiction.

6.4

1. **Non**, il ne converge pas vers 0 : l'écart absolu $|Y_N - Np|$ **croît** typiquement en $\sqrt{N}$. C'est l'écart **relatif** $|Y_N - Np|/N$ qui tend vers 0.
2. Parce que la fréquence s'approche de $6/49$ uniquement parce qu'on divise par un N croissant (dilution), pas parce que les sorties manquantes sont rattrapées (compensation).
3. Une **martingale** : sous H_0 , $(Y_N - Np)$ en est une, et le théorème d'arrêt optionnel interdit tout système de pari gagnant fondé sur le passé. ``