

01 — Fondations probabilistes

Table des matieres

[Pourquoi ce document](#)

[0.1 — Le processus de Bernoulli](#)

[0.2 — La probabilité d'un numéro à un tirage : \$p = 6/49\$](#)

[0.3 — Indépendance entre tirages vs tirage sans remise](#)

[0.4 — Espérance, variance, écart-type](#)

[Réponses aux exercices](#)

Niveau : base → intermédiaire (traité en profondeur). **Prérequis** : notion de probabilité, dénombrement (combinaisons), notion d'indépendance. **Couvre les fiches source** : 0.1, 0.2, 0.3, 0.4 de concepts_FR.md. **Documents suivants** : 02_lois_de_probabilite.md (toutes les lois dérivent de ces fondations).

Pourquoi ce document

Tout le projet iAlexMG repose sur une seule **hypothèse nulle** : *le Lotto 6/49 est un tirage uniforme et indépendant*. Cette hypothèse n'est pas une vague intuition — c'est un **objet mathématique précis**, le *processus de Bernoulli*, dont découlent par construction toutes les lois (binomiale, géométrique, hypergéométrique, Beta) et toutes les références (plancher d'entropie, posteriors bayésiens) du reste du projet.

Ce premier document pose ces fondations. On y établit quatre choses qui reviendront constamment : (0.1) **ce qu'est** le modèle nul ; (0.2) **la constante pivot** $p = 6/49$ et sa démonstration ; (0.3) la distinction subtile mais cruciale entre **indépendance dans le temps** et **dépendance au sein d'un tirage** ; (0.4) les **moments** (espérance, variance, écart-type) qui transforment ce modèle en prédictions chiffrées et testables.

Chiffres de référence du projet, utilisés tout au long : $N = 4\,377$ tirages, 49 numéros, 6 tirés par tirage, donc $p = 6/49 \approx 0,1224$.

0.1 — Le processus de Bernoulli

En une phrase

Le modèle nul de tout le projet est une **pièce truquée** à $p = 6/49$, relancée à chaque tirage **sans aucune mémoire** : c'est le processus de Bernoulli.

Intuition

Concentrons-nous sur **un seul numéro**, disons le 17. À chaque tirage, deux choses seulement peuvent arriver : soit le 17 fait partie des 6 numéros tirés (**succès**), soit non (**échec**). Sa probabilité de succès est $p = 6/49$, la même à chaque fois.

Imagine donc une pièce de monnaie biaisée qui tombe sur « face » avec probabilité $6/49 \approx 12,24\%$. À chaque nouveau tirage, on relance cette pièce. La pièce **n'a pas de mémoire** : qu'elle soit tombée sur face dix fois d'affilée ou jamais depuis un an, sa probabilité au prochain lancer reste exactement $6/49$. C'est la **brique élémentaire** du projet. Tous les phénomènes plus riches — combien de fois sur N tirages, combien de temps avant la prochaine sortie, combien de pairs par tirage — ne sont que des **questions différentes posées à cette même pièce**.

La force du modèle est sa pauvreté : il n'a qu'un seul paramètre, p , et une seule hypothèse de comportement, l'absence de mémoire. C'est précisément cette pauvreté qui le rend **réfutable** : si les données réelles montraient la moindre mémoire (un numéro « dû », une « série en avance »), elles trahiraient un écart au modèle. Le projet entier consiste à chercher cet écart — et à ne pas le trouver.

Formalisation

Épreuve de Bernoulli. Une variable aléatoire X est dite *de Bernoulli* de paramètre $p \in [0,1]$, notée $X \sim \text{Bernoulli}(p)$, si elle prend la valeur 1 (succès) avec probabilité p et 0 (échec) avec probabilité $1 - p$. Sa fonction de masse s'écrit de façon compacte :

$$P(X = x) = p^x(1 - p)^{1-x}, \quad x \in \{0,1\}.$$

Ses deux premiers moments (démontrés en §0.4) :

$$\mathbb{E}[X] = p, \quad \text{Var}(X) = p(1 - p).$$

Processus de Bernoulli. En suivant un numéro fixé au fil du temps, on définit pour chaque tirage $t = 1, 2, \dots, N$ l'**indicatrice**

$$X_t = \mathbf{1}\{\text{le numéro suivi est tiré au tirage } t\}.$$

La suite $(X_t)_{t \geq 1}$ est un **processus de Bernoulli** si elle vérifie **deux hypothèses**, qu'il faut toujours garder explicites car ce sont *elles* que les tests du projet mettent à l'épreuve :

1. **(H-indép) Indépendance.** Les X_t sont mutuellement indépendantes : la sortie au tirage t n'apporte aucune information sur le tirage t' pour $t \neq t'$. Formellement, pour tout sous-ensemble fini d'instantanés, $P(X_{t_1} = x_1, \dots, X_{t_k} = x_k) = \prod_{i=1}^k P(X_{t_i} = x_i)$.

2. **(H-stat) Stationnarité de p .** Le paramètre est **constant dans le temps** : $P(X_t = 1) = p$ pour tout t , sans dérive, tendance, ni saisonnalité.

Une suite vérifiant (H-indép) et (H-stat) est dite **i.i.d.** (indépendante et identiquement distribuée) de loi Bernoulli(p). C'est la définition exacte du **modèle nul** H_0 du projet. Son **alternative** H_1 est simplement sa **négarion** : au moins une des deux hypothèses tombe — soit le tirage a une **mémoire** (violation de H-indép : « numéro dû », « numéro en avance », autocorrélation), soit p **dérive ou n'est pas uniforme** (violation de H-stat). Chaque test de la Phase 1 (document 06) décline ce H_1 générique en une forme précise et mesurable.

Ce qui violerait ces hypothèses (et que les tests cherchent) :

- *Violation de (H-indép)* : une **autocorrélation** non nulle de la série (X_t) — par exemple $P(X_{t+1} = 1 \mid X_t = 1) \neq p$. C'est exactement la forme que prendraient la « numéro en avance » (autocorrélation positive) ou un effet de « numéro dû » (anti-persistance). Testé en Phase 1 (T2, T3, T4).
- *Violation de (H-stat)* : une **dérive** $p = p(t)$ — un numéro qui deviendrait plus probable avec les années (boule usée, changement de machine). Testé par les analyses de stabilité sur sous-périodes (T6).

Lien avec les lois dérivées. Une fois le processus posé, chaque loi du projet répond à une question différente sur **la même** suite (X_t) :

Question posée	Loi obtenue	Document
Combien de succès sur N tirages ?	Binomiale $\text{Bin}(N, p)$	02 (§1.1)
Combien de tirages avant le 1 ^{er} succès ?	Géométrique $\text{Geom}(p)$	02 (§1.2)
Quelle croyance sur p après les données ?	Posterior Beta	04 (§3.2)
Quel log-loss minimal est atteignable ?	Plancher d'entropie $H(p)$	07 (§5.5)

Toutes ces lois sont des **conséquences** du processus de Bernoulli, pas des hypothèses indépendantes. C'est pourquoi ce document est le socle de tous les autres.

Dans iAlexMG

Le processus de Bernoulli **est** l'hypothèse nulle H_0 commune à *tous* les tests du projet. Concrètement :

- La constante $p = 6/49$ est codée une seule fois (`single_draw_probability` dans `config.py`) et alimente chaque test.
- Le **Test 1** (fréquences) demande : « *le nombre de sorties de chaque numéro sur $N = 4\,377$ tirages est-il compatible avec $\text{Bin}(N, 6/49)$?* » — c’est lire (X_t) comme un comptage binomial.
- Le **Test 2** (gaps) lit la **même** suite comme des temps d’attente géométriques.
- Le **Test 4** teste directement (H-indép) via l’autocorrélation et les runs.

L’élégance du projet tient à ce que tous ces tests interrogent **un unique modèle génératif** sous des angles différents. S’il était faux, au moins l’un d’eux devrait sonner l’alarme. Aucun ne le fait de façon exploitable.

Pièges & malentendus

- « **Sans mémoire** » ne veut pas dire « **équilibré à court terme** ». Le processus n’impose aucune compensation : une suite de plusieurs sorties rapprochées du même numéro est parfaitement compatible avec H_0 . L’absence de mémoire *interdit* à un numéro d’être « dû » — c’est le contraire de l’intuition courante (voir le mythe du joueur, §7.1).
- **Confondre les deux hypothèses.** (H-indép) et (H-stat) sont distinctes : on peut imaginer une série indépendante mais avec un p qui dérive (stationnarité violée), ou un p constant mais des tirages corrélés (indépendance violée). Les tests ne visent pas les mêmes hypothèses.
- **Bernoulli $\neq$ binomiale.** Bernoulli décrit *une* épreuve (ou la suite des épreuves) ; la binomiale décrit le *comptage* sur un nombre fixé d’épreuves. La confusion est fréquente parce que la binomiale est une somme de Bernoulli.
- **Le modèle suit un numéro, pas un tirage.** Le processus de Bernoulli s’applique à l’indicatrice d’un **numéro donné** dans le temps. Au sein d’un même tirage, les 6 numéros ne sont pas indépendants (voir §0.3).

Pour vérifier ta compréhension

1. On observe que le numéro 7 n’est pas sorti depuis 20 tirages. Sous le processus de Bernoulli, quelle est la probabilité qu’il sorte au prochain tirage ?
2. Parmi ces deux observations, laquelle violerait (H-indép) et laquelle (H-stat) ?
 - (a) Le numéro 13 sort 18 % du temps avant 2000 et 9 % après.
 - (b) Après chaque sortie du 13, la probabilité qu’il ressorte au tirage suivant est de 20 %.

3. Vrai ou faux : « Comme le modèle est sans mémoire, sur 49 tirages chaque numéro doit sortir exactement une fois en moyenne, donc une suite de 49 tirages sans le 7 est impossible sous H_0 . »

(Réponses [à la fin.](#))

Pour aller plus loin

- **Généralisation : processus de comptage.** Le processus de Bernoulli est la version à temps discret du **processus de Poisson** (temps continu) ; les gaps géométriques deviennent alors des inter-arrivées exponentielles. Utile pour penser les « temps d'attente » de façon unifiée (voir §1.2).
- **Chaînes de Markov.** Relâcher (H-indép) en autorisant une dépendance au seul tirage précédent donne une **chaîne de Markov à deux états**. La cascade n-grammes (§6.3) peut se lire comme un test contre une telle structure d'ordre supérieur.
- **Échangeabilité et de Finetti.** En bayésien, on ne suppose pas p connu mais on pose une suite *échangeable* ; le théorème de de Finetti garantit qu'elle s'écrit comme un mélange de processus de Bernoulli — ce qui fonde le traitement Beta-Bernoulli du document 04.

0.2 — La probabilité d'un numéro à un tirage : $p = 6/49$

En une phrase

La probabilité qu'un numéro précis figure parmi les 6 tirés sur 49 vaut exactement $p = 6/49 \approx 0,1224$, et cette valeur est la **constante pivot** de tout le projet.

Intuition

Il y a **6 places** à pourvoir et **49 candidats** strictement équivalents. Par symétrie, chaque candidat a la même « part du gâteau ». Les 6 places se partagent entre 49 numéros, donc chaque numéro décroche $6/49$ de chance d'être servi. Aucun calcul savant n'est nécessaire pour *sentir* le résultat ; la formalisation ne fait que le rendre rigoureux et montrer qu'il survit à deux raisonnements différents.

Formalisation

On veut $p = P(\text{un numéro fixé, disons } a, \text{ est parmi les 6 tirés})$. Le tirage choisit un sous-ensemble de 6 numéros parmi 49, **uniformément** parmi les $\binom{49}{6}$ sous-ensembles possibles.

Démonstration 1 — par dénombrement. Le numéro a est tiré si et seulement si le sous-ensemble tiré contient a . Un tel sous-ensemble est obtenu en fixant a puis en choisissant les 5 autres numéros parmi les 48 restants : il y en a $\binom{48}{5}$. D'où

$$p = \frac{\binom{48}{5}}{\binom{49}{6}}.$$

Développons avec $\binom{n}{k} = \frac{n!}{k!(n-k)!}$:

$$\frac{\binom{48}{5}}{\binom{49}{6}} = \frac{\frac{48!}{5! 43!}}{\frac{49!}{6! 43!}} = \frac{48!}{5! 43!} \cdot \frac{6! 43!}{49!} = \frac{48! \cdot 6!}{5! \cdot 49!} = \frac{6!}{5!} \cdot \frac{48!}{49!} = \frac{6}{49}.$$

Démonstration 2 — par symétrie et linéarité. Numérotions les 6 positions tirées 1, ..., 6. Par symétrie du tirage uniforme, le numéro a a la même probabilité d'occuper n'importe quelle position : avant tout conditionnement, la position j est occupée par chacun des 49 numéros avec probabilité $1/49$, donc $P(a \text{ en position } j) = 1/49$ pour tout j . Or a ne peut occuper **qu'au plus une** position (les 6 numéros tirés sont distincts), donc les événements $\{a \text{ en position } j\}$ sont **mutuellement exclusifs**. La probabilité que a soit tiré est la réunion de ces 6 événements disjoints :

$$p = \sum_{j=1}^6 P(a \text{ en position } j) = 6 \times \frac{1}{49} = \frac{6}{49}.$$

Valeur numérique : $p = 6/49 = 0,12244 \dots \approx 12,24 \%$.

Généralisation. Pour un jeu « r tirés parmi m » (sans remise, tirage uniforme), le même argument donne

$$p = \frac{\binom{m-1}{r-1}}{\binom{m}{r}} = \frac{r}{m}.$$

C'est exactement ce qui rend la configuration **retargetable** : changer de jeu revient à changer r et m .

Dans iAlexMG

$p = 6/49$ est la constante la plus utilisée du projet : c'est le `single_draw_probability` de `config.py`, **calculée** à partir de `n_drawn = 6` et `n_balls = 49` (et non codée en dur), précisément pour que le pipeline soit rejouable sur un autre jeu en ne changeant qu'un seul objet de configuration (`GameConfig`, voir §8.4). Cette constante apparaît :

- comme paramètre du modèle nul binomial (T1) et géométrique (T2) ;
- comme cible des intervalles de confiance et crédibles (« l'IC contient-il $6/49$? ») ;

- dans le plancher d'entropie $H(6/49) \approx 0,3718$ nat (§5.5) ;
- dans la référence « hit@6 » $= 6 \times 6/49 \approx 0,735$ (§5.7).

Pièges & malentendus

- **1/49 vs 1/48 à la 2^e position.** On entend parfois : « à la première position c'est 1/49, mais une fois une boule sortie il n'en reste que 48, donc à la deuxième position c'est 1/48 ». C'est confondre une probabilité **conditionnelle** (sachant que a n'a pas été tiré en position 1) avec la probabilité **marginale** (non conditionnée). *Marginalement*, par symétrie, chaque position vaut 1/49 pour a ; la somme des 6 positions disjointes donne bien 6/49. La démonstration 2 ci-dessus rend ce point explicite.
- **6/49 n'est pas la probabilité de gagner.** C'est la probabilité qu'un numéro donné soit tiré, pas celle d'avoir les 6 bons (qui vaut $1/\binom{49}{6} \approx 7,15 \times 10^{-8}$). Deux questions différentes.
- **Équiprobabilité supposée.** Toute la démonstration repose sur l'hypothèse que le tirage est **uniforme** sur les $\binom{49}{6}$ combinaisons. C'est précisément l'hypothèse H_0 ; $p = 6/49$ en est une conséquence, pas une vérité indépendante.

Pour vérifier ta compréhension

1. Recalcule p pour un jeu « 7 tirés parmi 50 » avec les deux méthodes. Donne la valeur décimale.
2. Un ami affirme : « La probabilité que le 7 soit le **premier** numéro tiré vaut 1/49, donc sur les 6 positions sa probabilité d'être tiré est 6/49 ; mais comme les positions s'épuisent, le vrai calcul devrait donner moins que 6/49. » Où est l'erreur ?
3. Sans calculer $\binom{48}{5}$ ni $\binom{49}{6}$ explicitement, montre que leur rapport vaut 6/49.

(Réponses [à la fin.](#))

Pour aller plus loin

- **Espérance par linéarité.** La démonstration 2 est un cas particulier de la linéarité de l'espérance appliquée à des indicatrices ; on la réutilise en §0.4 pour calculer l'espérance d'une somme de numéros sans jamais supposer l'indépendance.
 - **Symétrie d'échangeabilité.** L'argument « toutes les positions se valent » est une symétrie d'échangeabilité ; elle reviendra pour justifier la corrélation mécanique $-1/48$ (§0.3) et la loi hypergéométrique (§1.3).
-

0.3 — Indépendance entre tirages vs tirage sans remise

En une phrase

Le hasard du Lotto vit dans **deux régimes** : **entre** tirages, indépendance totale (aucune mémoire) ; **au sein** d'un tirage, tirage **sans remise** qui rend les 6 numéros légèrement et mécaniquement **dépendants** entre eux.

Intuition

Imagine une urne de 49 boules. Pour **un tirage**, on pioche 6 boules **sans les remettre** : forcément, la sortie d'une boule modifie ce qui reste pour les autres piochées du même tirage — elles ne peuvent pas être identiques, donc elles sont *dépendantes*. Puis, pour le tirage **suivant**, on remet **toutes** les boules et on repart à neuf : l'urne est *réinitialisée*, aucune trace du passé. C'est la clé : la dépendance existe **horizontalement** (à l'intérieur d'un tirage) mais jamais **verticalement** (d'un tirage à l'autre).

Cette distinction n'est pas de la pédanterie : elle dicte **quelle loi** utiliser. Suivre *un* numéro dans le temps → on reste dans le monde indépendant → loi **binomiale**. Regarder la composition *d'un* tirage (combien de pairs, quelle somme) → on est dans le monde sans remise → loi **hypergéométrique**.

Formalisation

Régime vertical (entre tirages) — indépendance. C'est l'hypothèse (H-indép) du processus de Bernoulli : pour un numéro fixé, $(X_t)_t$ sont indépendantes. Conséquence directe : pour *un* numéro suivi dans le temps, le comptage $\sum_t X_t$ suit **exactement** une binomiale (§1.1), car somme d'indicatrices indépendantes.

Régime horizontal (au sein d'un tirage) — sans remise. Fixons un tirage et deux numéros distincts a et b . Notons X_a, X_b leurs indicatrices de présence dans ce tirage. Le tirage choisit 6 numéros parmi 49 sans remise, uniformément. Alors :

$$P(X_a = 1) = P(X_b = 1) = \frac{6}{49} = p,$$
$$P(X_a = 1, X_b = 1) = \frac{\binom{47}{4}}{\binom{49}{6}} = \frac{6 \cdot 5}{49 \cdot 48} = \frac{30}{2352} \approx 0,01276.$$

(La dernière égalité : choisir a et b puis 4 autres parmi 47.) Comparons au cas indépendant, où l'on aurait $p^2 = (6/49)^2 \approx 0,01499$. La présence conjointe est **moins** probable que sous l'indépendance : les numéros se « font concurrence » pour les 6 places. Quantifions par la **covariance** :

$$\text{Cov}(X_a, X_b) = P(X_a = 1, X_b = 1) - p^2 = \frac{6 \cdot 5}{49 \cdot 48} - \left(\frac{6}{49}\right)^2.$$

Mettons au même dénominateur :

$$\text{Cov}(X_a, X_b) = \frac{6}{49} \left(\frac{5}{48} - \frac{6}{49} \right) = p \left(\frac{5}{48} - \frac{6}{49} \right) \approx -0,002239.$$

Comme $\text{Var}(X_a) = p(1-p) \approx 0,10742$ (voir §0.4), le **coefficient de corrélation** vaut

$$\rho(X_a, X_b) = \frac{\text{Cov}(X_a, X_b)}{\text{Var}(X_a)} = \frac{p \left(\frac{5}{48} - \frac{6}{49} \right)}{p(1-p)} = -\frac{1}{48}.$$

Résultat remarquable : la corrélation mécanique entre deux numéros d'un même tirage vaut exactement $-\frac{1}{n_{\text{balls}}-1} = -\frac{1}{48} \approx -2,08\%$, **indépendamment** de p . C'est le prix universel du tirage sans remise. Faible (2 %), mais réel et négatif : si un numéro sort, les autres sont très légèrement *moins* probables, car une place sur six est prise.

Forme générale. Pour un tirage sans remise de r éléments parmi m , deux indicatrices distinctes ont une corrélation $\rho = -\frac{1}{m-1}$. Quand $m \rightarrow \infty$ (grande population), $\rho \rightarrow 0$: le sans-remise **converge vers** l'indépendance, et l'hypergéométrique vers la binomiale (§1.3).

Pourquoi la binomiale reste valide pour un numéro dans le temps. Le sans-remise ne concerne que la composition *interne* d'un tirage. D'un tirage à l'autre, l'urne est remise à neuf : l'indicatrice X_t d'un numéro donné ne « voit » jamais la dépendance horizontale, seulement la suite verticale indépendante. Donc $\sum_{t=1}^N X_t \sim \text{Bin}(N, p)$ exactement, sans correction.

Dans iAlexMG

Cette distinction tranche **quel outil** s'applique à quel test :

- **Binomiale (vertical)** : Test 1 (fréquence d'un numéro sur N tirages), bandes de confiance, séries (T3). On suit un numéro dans le temps $\rightarrow$ indépendance $\rightarrow$ binomiale exacte.
- **Hypergéométrique (horizontal)** : Test 5, loi exacte du **nombre de numéros pairs** par tirage (24 pairs et 25 impairs parmi 1–49, tirés sans remise). Ici la binomiale serait *fausse* car elle ignorerait l'épuisement du stock.
- **Correction « population finie »** : dans le χ^2 d'uniformité (T1), la corrélation $-1/48$ entre cellules explique pourquoi la p-value est obtenue par **Monte-Carlo** (qui rejoue de vrais tirages sans remise) plutôt que par la loi du χ^2 asymptotique naïve (voir §2.6, §2.8).

Pièges & malentendus

- **Croire que sans remise $\Rightarrow$ mémoire entre tirages.** Non : le sans-remise est *interne* à un tirage. Les tirages successifs restent indépendants. Confondre les deux mène droit au mythe du numéro en retard.

- **Appliquer la binomiale à la parité d'un tirage.** Compter les pairs parmi 6 numéros tirés sans remise n'est *pas* binomial : c'est hypergéométrique. L'erreur sous-estime la concentration de la distribution.
- **Négliger $-1/48$ « parce que c'est petit ».** Sur 49 cellules, ces petites corrélations négatives s'accumulent et modifient la loi nulle du χ^2 : les ignorer fausse la p-value. Petit ne veut pas dire nul.
- **Penser que ρ dépend de p .** Le résultat $\rho = -1/48$ est purement combinatoire ; il ne dépend que de la taille de la population, pas de p .

Pour vérifier ta compréhension

1. Pour le jeu 6/49, calcule $P(X_a = 1 \mid X_b = 1)$ (probabilité que a sorte sachant que b est sorti, même tirage). Est-elle supérieure ou inférieure à $6/49$? Pourquoi est-ce cohérent avec $\rho < 0$?
2. Vrai ou faux : « Comme deux numéros d'un même tirage sont corrélés négativement, suivre le numéro 7 sur 4 377 tirages devrait aussi montrer une corrélation entre tirages. »
3. Dans un hypothétique jeu « 6 parmi 1000 », que vaut la corrélation entre deux numéros d'un tirage ? Qu'en conclus-tu sur le choix binomiale vs hypergéométrique ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Loi hypergéométrique (§1.3).** Formalise complètement le régime horizontal : loi exacte du nombre de succès dans un tirage sans remise, ses moments, et le **facteur de correction population finie** $\frac{m-r}{m-1}$ sur la variance.
- **Échangeabilité.** Les X_a d'un même tirage sont *échangeables* (toute permutation des numéros laisse la loi inchangée) ; la corrélation commune constante $-1/48$ est une signature de cette structure.
- **Effet sur les degrés de liberté.** La contrainte « exactement 6 succès par tirage » retire un degré de liberté ; c'est la raison profonde de la correction du χ^2 abordée en §2.6.

0.4 — Espérance, variance, écart-type

En une phrase

L'espérance dit **où** se trouve le « normal », la variance et l'écart-type disent **de combien** on s'en écarte typiquement — et ces trois nombres transforment le modèle nul en **prédictions chiffrées** (bandes, comptes attendus, z-scores).

Intuition

Avant de crier « anomalie ! », il faut savoir à quoi ressemble le *normal* et quelle est sa *marge de fluctuation naturelle*. L'espérance fixe le centre de gravité ; l'écart-type fixe l'échelle des écarts qu'on doit considérer comme banals. Tout le travail des tests consiste à mesurer un écart observé **en unités d'écart-type** : un numéro qui sort 570 fois quand on en attend 536 est-il suspect ? Réponse seulement si l'on connaît σ . Ici $\sigma \approx 21,7$, donc 570 est à $+1,6\sigma$ — banal.

Formalisation

Définitions. Pour une variable aléatoire X :

$$\mathbb{E}[X] = \sum_x x P(X = x) \quad (\text{centre}), \quad \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \quad (\text{dispersion}),$$

$$\sigma(X) = \sqrt{\text{Var}(X)} \quad (\text{écart-type, même unité que } X).$$

Moments d'une Bernoulli. Pour $X \sim \text{Bernoulli}(p)$, comme $X \in \{0,1\}$ on a $X^2 = X$, donc $\mathbb{E}[X^2] = \mathbb{E}[X] = p$. D'où :

$$\mathbb{E}[X] = p, \quad \text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = p - p^2 = p(1 - p).$$

Deux propriétés-clés (à bien distinguer, car elles n'ont pas les mêmes conditions) :

- **Linéarité de l'espérance — toujours vraie, même sans indépendance :**

$$\mathbb{E}\left[\sum_i X_i\right] = \sum_i \mathbb{E}[X_i].$$

- **Additivité de la variance — vraie seulement sous indépendance (ou non-corrélation) :**

$$\text{Var}\left(\sum_i X_i\right) = \sum_i \text{Var}(X_i) + 2 \sum_{i < j} \text{Cov}(X_i, X_j).$$

$= 0$ si non corrélés

Application 1 — moments de la binomiale. Soit $Y = \sum_{t=1}^N X_t$ avec $X_t \sim \text{Bernoulli}(p)$ i.i.d. (le comptage d'un numéro sur N tirages). Par linéarité puis additivité (les X_t sont indépendants) :

$$\mathbb{E}[Y] = Np, \quad \text{Var}(Y) = Np(1 - p), \quad \sigma(Y) = \sqrt{Np(1 - p)}.$$

Avec les chiffres du projet ($N = 4\,377$, $p = 6/49$) :

$$\mathbb{E}[Y] = 4377 \times \frac{6}{49} \approx 535,96, \quad \sigma(Y) = \sqrt{4377 \times 6/49 \times 43/49} \approx 21,68.$$

Donc, sous H_0 , **chaque numéro est attendu environ 536 fois, à ± 22 près**. Une bande à $\approx \pm 2\sigma$ (de ≈ 493 à ≈ 579) capture l'essentiel des fluctuations normales.

Application 2 — écart-type relatif et la loi en $1/\sqrt{N}$. Considérons la **proportion** observée $\hat{p} = Y/N$. Par les règles $\mathbb{E}[aX] = a\mathbb{E}[X]$ et $\text{Var}(aX) = a^2\text{Var}(X)$:

$$\mathbb{E}[\hat{p}] = p, \quad \text{Var}(\hat{p}) = \frac{p(1-p)}{N}, \quad \sigma(\hat{p}) = \sqrt{\frac{p(1-p)}{N}}.$$

L'**écart-type relatif** de la proportion décroît donc en $1/\sqrt{N}$:

$$\frac{\sigma(\hat{p})}{p} = \sqrt{\frac{1-p}{pN}} \propto \frac{1}{\sqrt{N}}.$$

Numériquement, pour $p = 6/49$ et $N = 4\,377$: $\sigma(\hat{p})/p = \sqrt{(43/49)/(6/49 \cdot 4377)} \approx 0,0405$, soit **$\pm 4,05\%$** . C'est la racine de toute l'inférence : pour **diviser par deux** l'incertitude relative, il faut **quadrupler** le nombre de tirages. C'est aussi pourquoi un *non-rejet* n'est informatif que si N est grand (analyse de puissance, §2.4) : avec 4 377 tirages, on détecterait un biais relatif de quelques pourcents, mais pas un biais infinitésimal.

Dans iAlexMG

Ces moments sont la **machine à fabriquer des prédictions testables** :

- **Bandes de confiance (T1, figure de fréquences)** : centre $Np \approx 536$, demi-largeur $\approx 2\sigma \approx 43$. Un numéro hors bande est candidat à l'anomalie (avant correction de Bonferroni, §2.5).
- **Comptes attendus du χ^2 (T1, T5)** : les $E_i = Np_i$ sont des espérances ; l'écart $(O_i - E_i)$ est jugé à l'aune de $\sqrt{E_i}$.
- **z-scores (T5)** : $z = (\bar{x}_{\text{obs}} - \mu_0)/\sigma$ — c'est l'écart à l'espérance, en unités d'écart-type, qui révèle le léger penchant vers les gros numéros ($z \approx 3,2$).
- **Plancher en $1/\sqrt{N}$** : justifie pourquoi $N = 4\,377$ suffit à exclure les biais *grossiers* mais pas à « prouver » l'aléa parfait.

Pièges & malentendus

- **Variance additive sans vérifier l'indépendance.** L'additivité de la variance **exige** la non-corrélation. Pour la somme des 6 numéros d'un tirage (corrélés à $-1/48$), on **ne peut pas**

simplement additionner les variances : il faut le terme de covariance (sinon on surestime la variance). C'est le lien direct avec §0.3.

- **Confondre σ (du comptage) et σ (de la proportion).** Le premier croît en $\sqrt{N}$ (l'écart absolu grandit), le second décroît en $1/\sqrt{N}$ (l'écart relatif rétrécit). Les deux sont vrais simultanément et ne se contredisent pas — c'est le cœur de « convergence $\neq$ remboursement » (§6.4).
- **Lire l'écart-type comme une borne.** σ est un écart *typique*, pas un maximum : des écarts à 2–3 σ arrivent régulièrement, surtout répétés sur 49 numéros.
- **Oublier les unités.** La variance est en « (sorties)² » ; seul l'écart-type est comparable au comptage. On raisonne presque toujours en σ .

Pour vérifier ta compréhension

1. Calcule l'espérance et l'écart-type du nombre de sorties d'un numéro sur seulement $N = 100$ tirages. Quel est l'écart-type **relatif** ? Compare-le aux 4,05 % obtenus pour $N = 4\,377$.
2. La somme S des 6 numéros d'un tirage a pour espérance $6 \times 25 = 150$ (les numéros 1–49 ont une moyenne de 25). Si l'on (à tort) supposait les 6 numéros indépendants, surestimerait-on ou sous-estimerait-on $\text{Var}(S)$? Justifie via le signe de la covariance.
3. Un numéro est sorti 600 fois sur 4 377 tirages. À combien d'écarts-types de l'espérance est-ce ? Dirais-tu que c'est suspect ?

(Réponses [à la fin.](#))

Pour aller plus loin

- **Théorème central limite (§1.4).** Justifie pourquoi Y (et surtout $\hat{p}$ et la somme S) sont approximativement gaussiens pour N grand — ce qui autorise les bandes à $\pm 1,96 \sigma$ et le z-test.
- **Loi des grands nombres (§6.4).** Formalise $\hat{p} \rightarrow p$; à mettre en regard du fait que l'écart absolu $|Y - Np|$, lui, *grandit* en $\sqrt{N}$. Cette opposition est le cœur mathématique de la réfutation du mythe du numéro en retard.
- **Inégalités de concentration.** Bienaymé-Tchebychev ($P(|Y - \mathbb{E}Y| \geq k\sigma) \leq 1/k^2$) et les bornes de Hoeffding donnent des garanties *non asymptotiques* sur la taille des écarts — utiles pour borner les fluctuations sans supposer la normalité.

Réponses aux exercices

0.1

1. $6/49 \approx 12,24\%$, exactement comme à n'importe quel autre tirage. Le processus est sans mémoire : les 20 tirages sans le 7 n'ont aucune influence. Croire le contraire est le mythe du numéro en retard (§7.1).
2.
 - (a) viole **(H-stat)** : le paramètre p change dans le temps ($18\% \rightarrow 9\%$). (b) viole **(H-indép)** : la probabilité dépend du tirage précédent ($20\% \neq 6/49$), il y a donc de la mémoire (auto-corrélation positive, type « numéro en avance »).
3. **Faux**, deux fois. D'abord « exactement une fois en moyenne sur 49 tirages » dit que l'espérance du comptage vaut $49 \times 6/49 = 6$... non : l'espérance sur 49 tirages est 6 sorties, pas 1. (La probabilité par tirage est $6/49$, pas $1/49$.) Ensuite, même l'espérance n'interdit rien : une suite de 49 tirages sans le 7 a une probabilité $(43/49)^{49} \approx 0,2\%$ — rare, mais **parfaitement possible** sous H_0 .

0.2

1. Méthode 1 : $p = \binom{49}{6} / \binom{50}{7} = 7/50$. Méthode 2 : $7 \times 1/50 = 7/50 = 0,14$. Les deux donnent $0,14 (= r/m)$.
2. L'erreur est de croire que « les positions s'épuisent » réduit la probabilité. Les 6 événements « a en position j » sont **mutuellement exclusifs** et chacun vaut *marginale* $1/49$; leur somme est donc exactement $6/49$, sans aucune décote. L'épuisement concerne les probabilités *conditionnelles*, pas la marginale.
3. $\frac{\binom{48}{5}}{\binom{49}{6}} = \frac{48!/(5!43!)}{49!/(6!43!)} = \frac{6!}{5!} \cdot \frac{48!}{49!} = \frac{6}{49}$: les 43! se simplifient, $6!/5! = 6$ et $48!/49! = 1/49$.

0.3

1. $P(X_a = 1 | X_b = 1) = \frac{P(X_a=1, X_b=1)}{P(X_b=1)} = \frac{6 \cdot 5 / (49 \cdot 48)}{6/49} = \frac{5}{48} \approx 0,1042$. C'est **inférieur** à $6/49 \approx 0,1224$: sachant qu'une place est déjà prise par b , il reste 5 places pour 48 numéros. Cohérent avec $\rho < 0$ (présence de b rend a moins probable).
2. **Faux**. La corrélation $-1/48$ est *horizontale* (au sein d'un tirage). Entre tirages, l'urne est réinitialisée $\rightarrow$ indépendance $\rightarrow$ aucune corrélation temporelle attendue. C'est exactement ce que confirme le Test 4.
3. $\rho = -1/(m-1) = -1/999 \approx -0,001$, négligeable. On en conclut que pour une grande population l'hypergéométrie est **bien approchée par la binomiale** : la distinction sans-remise / indépendance devient sans conséquence pratique.

0.4

1. $\mathbb{E}[Y] = 100 \times 6/49 \approx 12,24$; $\sigma(Y) = \sqrt{100 \times 6/49 \times 43/49} \approx 3,28$. Écart-type relatif = $3,28/12,24 \approx 26,8\%$. C'est **environ** $\sqrt{4377/100} \approx 6,6$ **fois plus grand** que les 4,05 % à $N = 4\,377$ — illustration directe de la loi en $1/\sqrt{N}$.
2. La covariance entre deux numéros d'un tirage est **négative** (§0.3). Le vrai $\text{Var}(S) = \sum \text{Var}(X_i) + 2 \sum_{i < j} \text{Cov}$ est donc *plus petit* que la somme des variances seules. Supposer l'indépendance (ignorer la covariance négative) **surestimerait** $\text{Var}(S)$.
3. $z = (600 - 535,96)/21,68 \approx +2,95$. C'est à près de 3σ : isolément, ce serait surprenant (p bilatérale $\approx 0,3\%$). Mais sur **49 numéros**, on s'attend à voir un tel extrême par pur hasard de temps en temps ; après correction de Bonferroni (seuil $\approx 0,05/49 \approx 0,001$), ce n'est plus significatif. À surveiller, pas à conclure (voir §2.5). ``